

TP1

Coleta de Dados com Python via APIs e WebScraping

Exercício 1 e 2.

1 - Categorias de Dados

Dados Estruturados: São dados organizados em um formato tabular rígido, o que facilita buscas e análises diretas. No dia a dia, uma planilha financeira simples de gastos exemplifica isso. Na área de dados, tabelas de um banco de dados relacional (SQL) armazenando transações de clientes representam bem essa categoria.

Dados Semiestruturados: Não possuem estrutura tabular fixa, mas utilizam marcadores ou tags para organizar os elementos hierarquicamente. Um exemplo é um e-mail, que possui campos definidos (remetente, assunto) combinados com texto livre. Em engenharia de dados, arquivos JSON ou XML usados para transferência de informações entre APIs são o padrão.

Dados Desestruturados: Trata-se de dados brutos, sem formato, modelo ou organização predefinida, exigindo processamento complexo. No dia a dia, fotografias, vídeos ou áudios gravados no celular entram aqui. No universo de dados, grandes volumes de texto não formatado ou arquivos de mídia em um Data Lake consumidos por algoritmos de IA são os principais exemplos.

Dados Temporais: São dados sequenciais e ordenados cronologicamente, coletados em intervalos de tempo para acompanhar a evolução de uma variável. No dia a dia, o registro da sua temperatura corporal medido a cada hora durante uma febre. Na área de dados, o monitoramento por minuto do preço de uma ação na bolsa de valores (Time Series) é um caso clássico

2 - Fontes de Dados

Arquivo

Conjunto de dados armazenados fisicamente ou em nuvem em formatos estruturados ou semiestruturados, como CSV, Excel, TXT, JSON.

Uma planilha CSV exportada por um sistema de ERP contendo o histórico mensal de vendas de uma loja varejista.

Normalmente, utiliza-se a biblioteca ``pandas`` com funções específicas como ``pd.read_csv()`` ou ``pd.read_excel()`` para carregar os dados diretamente em um `DataFrame`, ou a função nativa ``open()`` para leitura de arquivos de texto.

Banco de Dados

Sistema projetado para armazenar, gerenciar e organizar grandes volumes de dados de forma eficiente e segura, podendo ser relacional (SQL) ou não relacional (NoSQL).

Um banco de dados PostgreSQL ou MySQL gerenciando os cadastros, senhas e histórico de transações financeiras dos clientes de um banco digital.

O programa utiliza bibliotecas de conexão ou ORMs, como ``psycopg2`` (para PostgreSQL), ``sqlite3`` ou ``SQLAlchemy``, para estabelecer uma sessão, autenticar e executar queries que retornam os dados desejados.

Web (Web Scraping)

Dados que estão visíveis e disponíveis em páginas da internet e que precisam ser extraídos diretamente de seus códigos estruturais (geralmente HTML).

Um script que acessa um site imobiliário diariamente para extrair e monitorar os preços e endereços de apartamentos à venda em uma determinada região.

Geralmente, utiliza-se a biblioteca ``requests`` para fazer o download do código-fonte (HTML) da página e a biblioteca ``BeautifulSoup`` ou ferramentas como ``Selenium`` para navegar pela estrutura e raspar (extrair) o texto necessário.

API (Application Programming Interface)

Conjunto de rotinas e padrões que funciona como uma ponte ou interface para que diferentes sistemas de software se comuniquem e troquem dados estruturados (frequentemente em JSON) de forma controlada.

O aplicativo de Uber consultando a API do Google Maps para obter rotas, tempo estimado e coordenadas GPS do motorista em tempo real.

Faz-se uso da biblioteca `requests` para enviar requisições HTTP (como GET ou POST) aos endpoints (URLs) disponibilizados pela API, e o retorno, tipicamente em JSON, é convertido em dicionários nativos do Python para manipulação.